

Алгоритм типа UCS для обучения экспертов при ограниченном бюджете

Латыпов Ильгам Магданович

Научный руководитель: кандидат технических наук Дорн Ю. В.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: Информатика и вычислительная техника

17 июня 2026 г.

План работы

Контекст: В современных ML-системах нужно обучать набор моделей в онлайн-режиме и одновременно учитывать ограничения вычислительных ресурсов. Это приводит к задаче последовательного принятия решений с обучаемыми экспертами при ограниченном бюджете.

Проблема: Существующие методы либо не учитывают динамику обучения экспертов, и тогда в ранних раундах часто выбираются слабые модели, либо не используют дополнительный вычислительный бюджет, и тогда обучение идет медленнее.

Задача: Предложить алгоритм выбора экспертов, который одновременно учитывает динамику обучения и наличие бюджета, и провести его теоретический и экспериментальный анализ.

Среда и протокол взаимодействия

Среда и функция потерь

Пространство решений: $\mathbf{U}$, пространство исходов: $\mathbf{E}$.

Функция потерь: $\ell : \mathbf{U} \times \mathbf{E} \rightarrow \mathbb{R}_+$.

Эксперт

Эксперт $k \in [K]$ работает на подпространстве $\mathbf{U}_k \subseteq \mathbf{U}$ и на раунде t выдает решение $u_k^t \in \mathbf{U}_k$.

Протокол

- 1) выбрать $S_t \subseteq [K]$, $|S_t| \leq M$, и решение $u^t \in \mathbf{U}$;
- 2) наблюдать $\xi^t \sim D$ и понести потери $\ell(u^t, \xi^t)$;
- 3) для каждого $k \in S_t$ вычислить $\ell(u_k^t, \xi^t)$ и обновить эксперта k .

Постановка цели процедуры

Предположение 1: Стохастическая среда

$$\xi^t \stackrel{\text{iid}}{\sim} D, \quad \ell : \mathbf{U} \times \mathbf{E} \rightarrow [0, 1].$$

Ожидаемые потери решения:

$$L(u) := \mathbb{E}_{\xi \sim \mathcal{D}}[\ell(u, \xi)], \quad L_k^* := \min_{u \in \mathbf{U}_k} L(u), \quad L^* := \min_{k \in [K]} L_k^*.$$

Регрет процедуры:

$$\text{Reg}(T) := \sum_{t=1}^T \ell(u^t, \xi^t) - T \cdot L^*.$$

Эксперты: обозначения и предположение об обучаемости

История обучения и потери:

$$I_k(t) := \{\tau < t : k \in S_\tau\}, \quad n_k^t := |I_k(t)|, \quad (1)$$

$$L_k(t) := \frac{1}{n_k^t} \sum_{\tau \in I_k(t)} \ell(u_k^\tau, \xi^\tau). \quad (2)$$

Внутренний регрет эксперта:

$$R_k(t) := n_k^t (L_k(t) - L_k^*).$$

Предположение 2: Равномерное по времени ограничение регрета эксперта

Для эксперта k для любого $\delta \in (0, 1)$, с вероятностью не менее $1 - \delta$, для всех $t \geq 1$,

$$R_k(t) \leq U_k(n_k^t, \delta).$$

Идея: Введем доверительные границы на оптимальную потерю эксперта

$$\text{LCB}_k(t, \delta), \text{UCB}_k(t, \delta).$$

Доверительный интервал эксперта: структура и лемма

$$\text{LCB}_k(t, \delta) = L_k(t) - \underbrace{\frac{U_k(n_k^t, \frac{\delta}{2K})}{n_k^t}}_{\text{скорость обучения}}.$$

$$\text{UCB}_k(t, \delta) = L_k(t) + c_2 \underbrace{\sqrt{\frac{\log(4K(n_k^t)^2/\delta)}{n_k^t}}}_{\text{слагаемое концентрации}}.$$

Лемма (Корректность доверительных интервалов (Латыпов, 2026))

Пусть $\delta \in (0, 1)$ и выполнены Предположения 1,2. Тогда с вероятностью не менее $1 - \delta$ для любого k и любого $t \geq 1$ выполняется

$$\text{LCB}_k(t, \delta) \leq L_k^* \leq \text{UCB}_k(t, \delta).$$

Процедура сглаживания

Определение (Сглаживание)

Процедурой сглаживания называется рандомизированное отображение $v : \{H \subseteq \mathbf{U} : |H| \geq 1\} \rightarrow \mathbf{U}$, которое конечному набору решений $H = \{u^\tau : \tau \in Z\} \subseteq \mathbf{U}, |Z| \geq 1$, ставит в соответствие решение $u = v(H) \in \mathbf{U}$ так, что

$$\mathbb{E}_{u \sim v(H)}[L(u) \mid H] \leq \frac{1}{|Z|} \sum_{\tau \in Z} L(u^\tau), \quad L(u) = \mathbb{E}_{\xi \sim D}[\ell(u, \xi)].$$

Примеры

- 1) Если $\mathbf{U}$ выпукло и $\ell(\cdot, \xi)$ выпукла по u , можно брать среднее

$$u = \frac{1}{|Z|} \sum_{\tau \in Z} u^\tau.$$

- 2) Если пространство решений невыпукло, можно равновероятно выбрать одно решение из истории $\{u^\tau : \tau \in Z\}$.

Алгоритм M-LCB

- 1: **Input:** эксперты $\{\mathbf{U}_k\}_{k=1}^K$, бюджет M , процедура сглаживания v
- 2: **Output:** решения $\{u^t\}_{t=1}^T$, обучаемые множества $\{S_t\}_{t=1}^T$
- 3: Инициализировать каждого эксперта одним обновлением.
- 4: **for** $t = 1, 2, \dots, T$ **do**
- 5: $S_t \leftarrow \arg \min_{S \subseteq [K], |S|=M} \sum_{k \in S} \text{LCB}_k(t, \delta)$ ▷ Топ M наименьших LCB
- 6: $i_t \leftarrow \arg \min_{k \in S_t} \text{UCB}_k(t, \delta)$
- 7: $u^t \leftarrow v(\{u_{i_t}^\tau : \tau \in I_{i_t}(t)\})$ ▷ сглаживание эксперта i_t
- 8: Сыграть u^t , получить $\ell(u^t, \xi^t)$
- 9: **for** $k \in S_t$ **do**
- 10: Наблюдать $\ell(u_k^t, \xi^t)$ и обновить эксперта k
- 11: **end for**
- 12: **end for**

Алгоритм M-LCB

- 1: **Input:** эксперты $\{\mathbf{U}_k\}_{k=1}^K$, бюджет M , процедура сглаживания v
- 2: **Output:** решения $\{u^t\}_{t=1}^T$, обучаемые множества $\{S_t\}_{t=1}^T$
- 3: Инициализировать каждого эксперта одним обновлением.
- 4: **for** $t = 1, 2, \dots, T$ **do**
- 5: $S_t \leftarrow \arg \min_{S \subseteq [K], |S|=M} \sum_{k \in S} \text{LCB}_k(t, \delta)$ ▷ Топ M наименьших LCB
- 6: $i_t \leftarrow \arg \min_{k \in S_t} \text{UCB}_k(t, \delta)$
- 7: $u^t \leftarrow v(\{u_{i_t}^\tau : \tau \in I_{i_t}(t)\})$ ▷ сглаживание эксперта i_t
- 8: Сыграть u^t , получить $\ell(u^t, \xi^t)$
- 9: **for** $k \in S_t$ **do**
- 10: Наблюдать $\ell(u_k^t, \xi^t)$ и обновить эксперта k
- 11: **end for**
- 12: **end for**

Алгоритм M-LCB

- 1: **Input:** эксперты $\{\mathbf{U}_k\}_{k=1}^K$, бюджет M , процедура сглаживания v
- 2: **Output:** решения $\{u^t\}_{t=1}^T$, обучаемые множества $\{S_t\}_{t=1}^T$
- 3: Инициализировать каждого эксперта одним обновлением.
- 4: **for** $t = 1, 2, \dots, T$ **do**
- 5: $S_t \leftarrow \arg \min_{S \subseteq [K], |S|=M} \sum_{k \in S} \text{LCB}_k(t, \delta)$ ▷ Топ M наименьших LCB
- 6: $i_t \leftarrow \arg \min_{k \in S_t} \text{UCB}_k(t, \delta)$
- 7: $u^t \leftarrow v(\{u_{i_t}^\tau : \tau \in I_{i_t}(t)\})$ ▷ сглаживание эксперта i_t
- 8: Сыграть u^t , получить $\ell(u^t, \xi^t)$
- 9: **for** $k \in S_t$ **do**
- 10: Наблюдать $\ell(u_k^t, \xi^t)$ и обновить эксперта k
- 11: **end for**
- 12: **end for**

Алгоритм M-LCB

- 1: **Input:** эксперты $\{\mathbf{U}_k\}_{k=1}^K$, бюджет M , процедура сглаживания v
- 2: **Output:** решения $\{u^t\}_{t=1}^T$, обучаемые множества $\{S_t\}_{t=1}^T$
- 3: Инициализировать каждого эксперта одним обновлением.
- 4: **for** $t = 1, 2, \dots, T$ **do**
- 5: $S_t \leftarrow \arg \min_{S \subseteq [K], |S|=M} \sum_{k \in S} \text{LCB}_k(t, \delta)$ ▷ Топ M наименьших LCB
- 6: $i_t \leftarrow \arg \min_{k \in S_t} \text{UCB}_k(t, \delta)$
- 7: $u^t \leftarrow v(\{u_{i_t}^\tau : \tau \in I_{i_t}(t)\})$ ▷ сглаживание эксперта i_t
- 8: Сыграть u^t , получить $\ell(u^t, \xi^t)$
- 9: **for** $k \in S_t$ **do**
- 10: Наблюдать $\ell(u_k^t, \xi^t)$ и обновить эксперта k
- 11: **end for**
- 12: **end for**

Гарантии на глобальный регрет

Для ранее введенного регрета $\text{Reg}(T) := \sum_{t=1}^T \ell(u^t, \xi^t) - T \cdot L^*$ получены следующие оценки.

Лемма (Ограниченный рост регрета (Латыпов, 2026))

Пусть $\delta \in (0, 1)$ и выполнены Предположения 1, 2. Тогда с вероятностью не менее $1 - \delta$,

$$\text{Reg}(T) \leq \sum_{\tau \in I_{k^*}(T)} [\text{UCB}_{k^*}(\tau, \delta) - \text{LCB}_{k^*}(\tau, \delta)] + \frac{1}{M} \sum_{k=1}^K \sum_{\tau \in I_k(T)} [\text{UCB}_k(\tau, \delta) - \text{LCB}_k(\tau, \delta)].$$

Теорема (Ограниченный рост регрета (Латыпов, 2026))

Пусть $\alpha, \delta \in (0, 1)$, выполнены Предположения 1, 2. Каждый эксперт k удовлетворяет предположению 2 с

$$U_k(t, \delta) = O(t^\alpha c(\delta)),$$

Тогда с вероятностью не менее $1 - \delta$ регрет алгоритма M-LCB ограничено для всех $T \geq 1$:

$$\text{Reg}(T) = O\left(\sqrt{\frac{KT}{M} \log \frac{KT}{\delta}} + \left(\frac{K}{M}\right)^{1-\alpha} T^\alpha c(\delta)\right).$$

Гарантия на усредненный регрет

Средний регрет выбранного множества:

$$\text{Reg}_M(T) := \sum_{t=1}^T \left[\frac{1}{M} \sum_{k \in S_t} L_k^* - \bar{L}^* \right], \quad \bar{L}^* = \min_{|S|=M} \frac{1}{M} \sum_{k \in S} L_k^*.$$

Теорема (Ограниченный рост усредненного регрета (Латыпов, 2026))

Пусть $\alpha, \delta \in (0, 1)$, выполнены Предположения 1,2. Каждый эксперт k удовлетворяет предположению 2 с

$$U_k(t, \delta) = O(t^\alpha c(\delta)).$$

Тогда с вероятностью не менее $1 - \delta$ усредненный регрет алгоритма M -LCB ограничено для всех $T \geq 1$:

$$\text{Reg}_M(T) = O\left(\sqrt{\frac{KT}{M} \log \frac{KT}{\delta}} + \left(\frac{K}{M}\right)^{1-\alpha} T^\alpha c(\delta)\right).$$

Гарантия означает, что алгоритм системно дообучает **топ M лучших** экспертов.

Нижние границы на регрет

Теорема (Нижние границы (Латыпов, 2026))

Для класса задач $\mathcal{F}_\alpha$ – где ,

$$\sup_{f_k \in \mathcal{F}_\alpha, k \in [K]} \mathbb{E} \text{Reg}(T) \geq c_1 \sqrt{\frac{KT}{M}} + c_2 T^\alpha \left(\frac{K}{M} \right)^{1-\alpha}.$$

Следствие:

- 1) при $\alpha < 1/2$ доминирует цена exploration $\sqrt{KT/M}$;
- 2) при $\alpha \geq 1/2$ доминирует цена дообучения $T^\alpha (K/M)^{1-\alpha}$.

В Предположениях 1, 2 регрет M-LSB совпадает с нижней границей с точностью до логарифмов.

Эксперимент: дизайн и проверяемая гипотеза

Сценарий

$K = 10$ экспертов (ϵ -Greedy и UCB1), бюджеты обучения $M \in \{1, 2, 3, 4\}$.

Среда

Каждый эксперт управляет двухручным бандитом:


$$\mu_{k,1} = \frac{2}{10} \left(1 - \frac{k}{K}\right), \quad \mu_{k,2} = \frac{1}{10} \left(2 - \frac{k}{K}\right), \quad \mu_{k,2} - \mu_{k,1} = \frac{k}{10K}.$$

Что проверяем

- 1) У слабых экспертов ручки различаются легче, поэтому они быстрее сходятся.
- 2) M-LCB должен перераспределять бюджет к действительно сильным экспертам.
- 3) Сравнение проводится с LimitedAdvice и Smooth Corral.

Метрики: регрет, частота выбора экспертов, доля шагов обучения.

Эксперимент: результаты согласуются с теорией



Итог 1: у M-LCB более медленный рост регрета при всех проверенных бюджетах M .

Итог 2: У M-LCB регрет растет медленнее с ростом бюджета (Теорема **Ограниченный рост регрета**).

Итог 3: M-LCB обучает топовых экспертов (Теорема **Ограниченный рост усредненного регрета**).

- 1) Разработан алгоритм многоруких бандитов M-LCB, который учитывает скорость обучения экспертов и позволяет обновлять несколько моделей за раз.
- 2) **Теоретические гарантии:** Для предложенного алгоритма получены теоремы об ограничении регрета и теорема об ограничении усредненного регрета. Последняя означает, что M-LCB концентрирует обновления на M лучших экспертах.
- 3) **Нижняя граница задачи:** доказана нижняя граница $\sqrt{KT/M} + T^\alpha (K/M)^{1-\alpha}$ для рассматриваемой задачи, которой M-LCB соответствует с точностью до логарифмов.

Публикации по теме: Латыпов И. М., Дорн Ю. В. «Learnable Experts Orchestration With Multi-Armed Bandits», submitted, 2026.