

Алгоритм типа UCS для обучения экспертов при ограниченном бюджете

Латыпов Ильгам Магданович

Научный руководитель: к.т.н. Дорн Ю. В.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: Информатика и вычислительная техника

22 мая 2026 г.

Проблематика и актуальность исследования

- ▶ **Контекст:** Современные промышленные ML-системы (рекомендательные сервисы, алгоритмы динамического ценообразования) функционируют в онлайн-режиме под воздействием непрерывного потока данных.
- ▶ **Вызов оркестрации:** Архитектура системы требует координации множества одновременно обучающихся моделей (экспертов). На каждом шаге принятия решений возникают две подзадачи:
 - 1) Выбор оптимального подмножества моделей для распределения ограниченного раундового бюджета на дообучение.
 - 2) Выбор конкретной модели для генерации финального прогноза.
- ▶ **Ограничения существующих подходов:** Классические методы теории многоруких бандитов (MAB) либо предполагают стационарность («замороженность») базовых алгоритмов, либо не поддерживают одновременное параллельное обновление нескольких адаптивных стратегий.

Постановка задачи оркестрации в терминах МАВ

Задан набор из K обучаемых моделей (экспертов/рук): $\{a_i\}_{i=1}^K$.

В каждый дискретный момент времени $t = 1, \dots, T$ выполняется следующий протокол:

- 1) Алгоритм выбирает подмножество моделей $S_t \subset [K]$ фиксированного размера $|S_t| = M$, направляемых на обучение.
- 2) Из выбранного подмножества фиксируется решающая модель $a_t \in S_t$ для выдачи предсказания.
- 3) Поступает элемент данных ξ_t , алгоритм несёт потери $l_{a_t}^t(w_{a_t}^t) := \ell(g_{a_t}(w_{a_t}^t, \xi_t), \xi_t)$.
- 4) Значения функций потерь становятся доступными для наблюдения для моделей из множества S_t .

Цель исследования: Минимизация накопленного регрета (Regret) относительно наилучшего в ретроспективе фиксированного эксперта с оптимальными весами:

$$R(T) = \sum_{t=1}^T l_{a_t}^t(w_{a_t}^t) - T \min_{k \in [K]} \min_{w_k} \mathbb{E}_{\xi} \ell(g_k(w, \xi), \xi) \rightarrow \min$$

Обозначения и базовые предположения

- ▶ Данные поступают независимо и одинаково распределёнными: $\xi_t \sim D$.
- ▶ Каждая модель $k \in [K]$ параметризована вектором внутренних весов $w_k \in \mathbb{R}^n$.
Текущие потери: $l_k^t(w) = l(g_k(w, \xi_t), \xi_t)$.

Предположение (Скорость сходимости внутренних экспертов): Процедура оптимизации каждого эксперта k гарантирует сублинейный регрет на любом промежутке τ :

$$\forall k \in [K], \forall \tau \geq 1 : \sum_{i=1}^{\tau} l_k^i(w^i) - \min_w \sum_{i=1}^{\tau} l_k^i(w) \leq U_k(\tau) = O(\tau^\alpha c(\delta)), \quad \alpha \in (0, 1)$$

где τ — суммарное число раундов, в которых данная модель была выбрана для обучения.

Предлагаемое решение: Оценка потенциала обучения

Пусть $L_k(\tau) = \frac{1}{\tau} \sum_{i=1}^{\tau} l_k^i(w_k^i)$ — средние накопленные потери модели k за τ шагов обучения. С учётом функции сходимости $U_k(\tau)$ строятся асимптотические нижняя (LCB) и верхняя (UCB) доверительные границы для ожидаемого минимума потерь:

$$LCB(k, \tau, \delta) := L_k(\tau) - \frac{U_k(\tau)}{\tau} - c_1 \sqrt{\frac{\log(\tau/\delta)}{\tau}}$$

$$UCB(k, \tau, \delta) := L_k(\tau) + c_2 \sqrt{\frac{\log(\tau/\delta)}{\tau}}$$

Лемма (Теоретическая корректность доверительных границ)

С вероятностью не менее $1 - \delta$ для любого горизонта $\tau > 0$ и каждого эксперта $k \in [K]$ выполняется соотношение:

$$LCB(k, \tau, \delta) \leq \min_{w_k} \mathbb{E}_{\xi} l(g_k(w, \xi), \xi) \leq UCB(k, \tau, \delta)$$

Алгоритм Multi-play Learnable Confidence Bounds (M-LCB)

На каждом шаге функционирования системы $t = 1, \dots, T$:

- 1) **Формирование пула для обучения (S_t):** Выбирается набор из M моделей, минимизирующих сумму нижних доверительных границ:

$$S_t = \arg \min_{S \subset [K], |S|=M} \sum_{k \in S} LCB(k, \tau_k^t, \delta)$$

- 2) **Выбор прогнозного эксперта (a_t):** Внутри сформированного пула S_t фиксируется наиболее стабильная модель с минимальной верхней границей риска:

$$a_t = \arg \min_{k \in S_t} UCB(k, \tau_k^t, \delta)$$

- 3) **Стабилизация (Smoothing Wrapper):** Применяется процедура рандомизированного сглаживания для предотвращения расходимости шагов градиентного спуска внутренних моделей.
- 4) **Обновление параметров:** Фиксируются потери моделей, обновляются веса моделей w_k для всех $k \in S_t$.

Теоретические гарантии сходимости

Теорема (Верхняя граница накопленного регрета M-LCB)

Пусть функции локальной сходимости экспертов удовлетворяют условию $U_k(t, \delta) = O(t^\alpha c(\delta))$. Тогда с вероятностью не менее $1 - \delta$ полный регрет предложенного алгоритма M-LCB ограничен величиной:

$$R(T) \leq O \left(\sqrt{\frac{KT}{M} \log \frac{KT}{\delta}} + \left(\frac{K}{M} \right)^{1-\alpha} T^\alpha c(\delta) \right)$$

Структурный анализ аналитической оценки:

- ▶ $O \left(\sqrt{\frac{KT}{M}} \right)$ — плата за стохастическую неопределенность внешней среды.
- ▶ $O(T^\alpha)$ — неустранимый регрет, обусловленный временем сходимости внутренних весов самих моделей. Поскольку $\alpha < 1$, средний регрет стремится к нулю:
 $\lim_{T \rightarrow \infty} \frac{R(T)}{T} = 0.$

Сравнение с существующими подходами (State-of-the-Art)

Алгоритм / Ссылка	Learnable	Multi-arm	Multiple-play	Скорость роста регрета
CORRAL + wrapper [24]	✓	—	—	$\tilde{O}\left(\sqrt{KT} + K^\alpha T^{1-\alpha} + K^{1-\alpha} T^\alpha\right)$
EXP3.P + wrapper [24]	✓	—	—	$\tilde{O}\left(\sqrt{KT} + K^{\frac{1-\alpha}{2-\alpha}} T^{\frac{1}{2-\alpha}}\right)$
Dynamic Balancing [9]	✓	—	—	$\tilde{O}\left(\sqrt{KT} + K^{1-\alpha} T^\alpha\right)$
Lim. Advice [25]	—	✓	—	$\tilde{O}\left(\sqrt{\frac{KT \log K}{M}}\right)$
H-INF [33]	—	✓	—	$\tilde{O}\left(\max\{\sqrt{KT/M}, \sqrt{T \log K}\}\right)$
UCB multiple-play [20]	—	—	✓	$\tilde{O}\left(\sqrt{KT/M}\right)$
M-LCB [Данная работа]	✓	✓	✓	$\tilde{O}\left(\sqrt{\frac{KT}{M}} + (K/M)^{1-\alpha} T^\alpha\right)$

Вычислительный эксперимент

Объект исследования

Оркестрация $K = 10$ гетерогенных экспертов (смесь стратегий ε -Greedy и UCB1), управляющих многорукими бандитами Бернулли.

- ▶ **Сложность («субоптимальная ловушка»):** Модели низкого качества обладают более высокой скоростью сходимости. Это создает риск ошибочной фиксации мета-алгоритма на слабых экспертах на ранних этапах.
- ▶ **Цель:** Оценка способности алгоритма M-LCB эффективно распределять бюджет обучения M для идентификации истинно оптимальной модели.
- ▶ **Сравнение:** Сравнение M-LCB с алгоритмами *LimitedAdvice* и *Smooth Corral* при различных бюджетах $M \in \{1, 2, 3, 4\}$.

Вычислительный эксперимент: Результаты




Рис.: Результаты симуляции алгоритмов оркестрации. (a): Накопленный регрет. Панель (b): Частота выбора экспертов для принятия решения. Панель (c): Распределение шагов обучения.

Основные результаты, выносимые на защиту

- 1) **Теоретический протокол** совместной оркестрации прогнозирования и онлайн-обучения семейства моделей, формализованный в рамках концепции многоруких бандитов.
- 2) **Алгоритм M-LSB**, адаптивно распределяющий раундовый бюджет на дообучение экспертов на основе нижних доверительных границ (LSB).
- 3) **Теорема о сублинейной верхней границе накопленного регрета**, доказывающая сходимость предложенного метода.
- 4) **Результаты комплексного численного моделирования**, подтверждающие превосходство разработанного алгоритма над альтернативными подходами.